

实验3 论文实现报告-nbgao

作者: 高鹏曷

邮箱: nbgao@126.com

1. 论文介绍

论文标题: [An Analysis of Single Layer Networks in Unsupervised Feature Learning](#)

论文作者: Adam Coates, Honglak Lee, Andrew Y. Ng

发表时间: 2011 AISTATS(Artificial Intelligence and Statistics)

2. 主要方法

本论文的核心工作是使用无监督方法对图像数据集进行特征学习,然后通过提取图像特征,进行分类任务. 论文中特征学习的方法主要应用了以下4种:

1. 稀疏自编码器(sparse auto-encoders)
2. 稀疏玻尔兹曼机(sparse RBMs)
3. K-means聚类(K-means clustering)
4. 高斯混合模型(Gaussian mixtures)

论文中用于图像分类任务实验的数据集为NORB和CIFAR.

第1阶段 特征学习

特征学习主要包括了子块采样阶段,子块预处理阶段和无监督特征表示学习阶段.

(1) 子块采样阶段

对于每幅图像随机提取 m 个子块(sub-patch),每个子块的尺寸为 $w \times w$ 且通道数为 d .获得采样子块集合 $X = \{x^{(1)}, \dots, x^{(m)}\}$,每个块(patch)用 $x^{(i)} \in \mathbb{R}^N$,其中 $N = w \times w \times d$.

(2) 子块预处理阶段

1. 对所有采样的子块进行**标准化(Standardization)** (论文中是用正则化Normalization表示,标准化是其中的一种方法).标准化公式如下:

$$x'_{ij} = \frac{x_{ij} - u}{\sigma}$$

其中, x_{ij} 表示每个子块 i 行 j 列的像素值, u 表示每个子块内像素的平均值, σ 表示每个子块内像素的标准差.

2. 经过标准化后的所有子块可以选择性地使用**白化(whitening)** 操作.关于这个操作论文中没有细致介绍其原理,可以参考[其他资料](#).

(3) 无监督特征学习阶段

无监督学习算法作为一个"黑盒"利用数据集 X 和输出函数 $f: \mathbb{R}^N \rightarrow \mathbb{R}^K$, 该函数映射了输入子块向量 $x^{(i)}$ 到新的 K 维特征向量, 其中 K 为无监督算法的参数(K-means方法中表示聚类数). 第 k 个特征用 f_k 表示.

论文中的无监督学习方法包括了4种:稀疏自编码,稀疏RBMs,K-means聚类和高斯混合模型.

这里我们重点关注其中的**K-means聚类算法**.

在特征学习阶段K-means聚类算法用来从输入数据学习 K 个中心(centroids), 第 k 个中心用 $c^{(k)}$ 表示. 给定学习到的中心 $c^{(k)}$, 论文给出了2种特征映射 f .

1. 硬分配编码法(独热编码one-hot)

即与中心点距离最近的元素对应的 f_k 置为1, 其余的置为0.

$$f_k(x) = \begin{cases} 1 & \text{if } k = \operatorname{argmin}_j \|c^{(j)} - x\|_2^2 \\ 0 & \text{otherwise} \end{cases}$$

2. 基于triangle激活函数的soft软编码非线性映射

这里的soft是指一定的"松弛性", 即每个小于平均距离的元素对应的 f_k 置为与均值的差值, 其余的置为0.

$$f_k(x) = \max\{0, u(z) - z_k\}$$

其中, $z_k = \|c^{(j)} - x\|_2^2$ 表示元素与第 k 个中心的距离, $u(z)$ 表示 z 的均值.

第2阶段 特征提取

利用大小为 w 的感受野在图像上均匀滑动采样, 滑动步长为 s , 从而得到 $(\frac{n-w}{s} + 1) \times (\frac{n-w}{s} + 1) \times K$ 个提取到的特征子块, 每个特征子块值为该子块与各个特征中心的距离.

然后, 通过4象限池化卷积的方法将每个图像样本 $(\frac{n-w}{s} + 1) \times (\frac{n-w}{s} + 1) \times K$ 数量降到 $2 \times 2 \times K$. 最后, 将4象限的4个向量展平拼接得到每个图像样本 $4K$ 维度的特征向量.

第3阶段 图像分类

论文中采用的分类器是标准线性分类算法,实验中使用了L2正则化的SVM分类器进行分类.

分类器输入的每个样本是池化后展平的 $4K$ 特征维向量和对应标准线性分类算法的类别标签.然后将训练后的分类器模型对测试特征向量,进行预测对应的类别标签.实验中的结果准确率是通过交叉验证(cross-validation)来评分的.

3. 论文实验及结果

实验中主要4种参数可以变化:

1. 是否使用白化(whitening)操作
2. 特征的数量 K
3. 感受野滑动步长 s (stride)
4. 感受野的尺寸 w

另外,针对K-means聚类算法还有soft和hard两种特征映射方法可选择.

论文的实验结果表明:

1. 对于K-means聚类算法,由于其对数据相关性的不可见,**白化操作**是一种关键的预处理方法.
2. 经过100,200,400,800,1200,1600不同特征表示数(即聚类后的中心数)下的实验比较:**特征表示数 K** 越大,交叉验证准确率越高.
3. 经过1,2,4,8不同**感受野滑动步长 s (stride)**下的实验比较:由于滑动距离越短,每幅图像中提取到的块越多,获得的特征信息更多,因此滑动步长 s 取1时,交叉验证准确率最高.
4. 经过6,8,12不同**感受野尺寸**下的实验比较:由于感受野尺寸越小,每幅图像中提取到的块也更多,因此在一定范围内感受野尺寸越小,交叉验证准确率越高(不能过小,这样每个块包含的特征信息太少).
5. K-means算法中采用triangle激活函数的soft特征映射方法要比hard特征映射方法的交叉验证准确率高出许多(5%-10%).

论文最终结论:

使用白化操作,感受野滑动步长为1像素,感受野尺寸为6像素,更多的特征数量,K-means算法采用triangle激活函数特征映射等参数方法能够在CIFAR-10数据集和NORB数据集上取得最好的测试准确率能(分别为77.9%和97.0%).

4. 实验实现

论文的代码实现在lab3-Paper-Implement-{1|2|3}-nbgao的ipynb文件中.具体实现请查看以上ipynb文件.

实验的方法基本按照上述的实验方法和流程.

总体的实验框架是:

[特征学习阶段] 子块随机采样 => 子块标准化 => 子块白化

[特征学习阶段] => K-means聚类学习特征中心 => hard/soft特征映射

[特征提取阶段] => 感受野滑动提取子块特征 => 4象限平均池化 => 特征拼接

[图像分类阶段] => 数据集划分 => 训练SVM分类器 => 预测测试集类别 => 评分计算准确率

注:

1. 实验实现所采用的是MNIST数据集,由于实验时间有限的因素,实验中的部分参数设置并没有完全依据论文中给出的(如学习的特征数K等).
2. 由于4象限池化图像的尺寸可能为奇数,4个块的像素数不能保持一致,因此本人并未采用论文中的计算每一象限内总和的方法,而是使用了平均池化(mean pooling)的方法.计算平均值的方法其实与计算总和是等效的,且相比较计算综合的方法其不受每部分数量不一致的影响.


5. 实验结果

实验采用的数据集为MNSIT数据集,学习特征的数据数量分别采用了1000,5000,10000个样本.

实验中的主要参数:

- 数据集大小: data_num = 1000/5000/10000
- 单张图像采样块数: $M = 10$
- 采样块/感受野宽度: $W = 6$
- 感受野滑动步长: $S = 1$
- 聚类中心数: $K = 500/1000$

随机选取的100个聚类中心(centroid)可视化结果如下:



同原论文一样本人最后同样采用了交叉验证(cross-validation)的方法来测试模型预测的准确率.本人在实验中采用的是K折交叉验证(K-fold cross-validation),其中K取10.这样便可以得到10次数据集划分的测试分数,然后即可得到10次的平均准确率.

测试结果如下:

data_num	K	M	W	S	hard/soft	Accuracy
1000	1000	10	6	1	hard	87.8%
1000	1000	10	6	1	soft	95.1%

data_num	K	M	W	S	hard/soft	Accuracy
5000	500	10	6	1	hard	94.9%
5000	500	10	6	1	soft	97.2%
10000	500	10	6	1	hard	96.1%
10000	500	10	6	1	soft	98.1%

由以上实验结果可知:

1. 在1000样本数量,1000特征中心数量下,采用了triangle激活函数的soft特征映射方法相比hard特征映射方法,交叉验证准确率高出了7.3个百分点.
2. 在5000样本数量,500特征中心数量下,采用了triangle激活函数的soft特征映射方法相比hard特征映射方法,交叉验证准确率高出了2.3个百分点.
3. 10000样本数量,500特征中心数量,采用了triangle激活函数的soft特征映射方法相比hard特征映射方法,交叉验证准确率高出了2.0个百分点.
4. 在其他参数一致的情况下,样本数量越大,交叉验证准确率越高.

注:

同样样本数量下,不同特征中心数量的对比实验由于时间有限,没有进行实验,但可以根据推测,特征中心数K越大,交叉验证准确率越高.